

Användning av OpenPose för analys av sprintlöpning

Mikael Granqvist



Kandidatarbete i datateknik
Handledare: Jesper Winsten
Fakulteten för naturvetenskap och teknik
Åbo Akademi
2024

Granqvist, Mikael	2024
Användning av OpenPose för analys av sprintlöpning	
Datateknik, Fakulteten för naturvetenskap och teknik, Åbo Akademi	Handledare: Jesper Winsten
Sprintlöpning utövas av många idrottare runtom i världen. För att bli snabbare krävs träning av styrka och löpteknik. Biomekaniken inom sprintlöpning har undersökts för att förstå vad som krävs för att förbättra prestationen i ett sprintlopp. Ett exempel är mätningen av ledvinklar i olika faser av ett sprintlopp, för att möjliggöra optimering av vinklarna. För att kunna implementera denna kunskap i en idrottares prestation behöver löpningen analyseras på något vis. Bilder och videor av sprintlopp möjliggör granskning av löptekniken, men bara bilderna och videorna kan inte ge detaljerad information om till exempel ledvinklar. Mänsklig kroppsställningsestimering (<i>eng.</i> Human Pose Estimation, HPE) är en teknik inom datorseende som används bland annat i rörelseanalys. Syftet med denna avhandling är att undersöka användningen av OpenPose för analys av sprintlöpning. OpenPose är en HPE-metod som i realtid kan detektera leder på människokroppen i bilder och videor. I denna avhandling presenteras först grundläggande bakgrundsinformation om artificiell intelligens, maskininlärning och djupinlärning. Vidare förklaras artificiella neurala nätverk och faltningsnätverk. Faltningsnätverk används för att extrahera egenskaper från bilder och dessa nätverk används även i OpenPose. I denna avhandling undersöks användningen av OpenPose i tre tidigare gjorda studier. I studierna mäts noggrannheten av OpenPose i olika former av löpning. Till slut diskuteras argument för och mot användningen av OpenPose för analys av sprintlöpning. Argumenten visar att OpenPose inte ännu är tillräckligt noggrann för att användas effektivt i analysen.	
Nyckelord	
Sprintlöpning, Djupinlärning, Faltningsnätverk, Kroppsställningsestimering, OpenPose	
Datum: 07.05.2024	Sidantal: 20

Innehåll

1. Introduktion.....	1
2. Bakgrund.....	2
2.1. Sprintlöpning.....	2
2.1.1. Biomekanik i sprintlöpning.....	2
2.2. Artificiell intelligens	4
2.3. Maskininlärning	5
2.4. Djupinlärning	6
2.4.1. Artificiella neurala nätverk.....	6
2.4.2. Falttningsnätverk	8
3. Mänsklig kroppsställningsestimering.....	10
3.1. Tvådimensionell kroppsställningsestimering.....	11
3.2. Tredimensionell kroppsställningsestimering	12
4. OpenPose.....	13
4.1. Arkitektur	15
4.2. OpenPose för analys av sprintlöpning.....	16
4.2.1. Sprintlöpning mellan koner	16
4.2.2. Häcklöpning	17
4.2.3. Löpning på löpband.....	18
5. Diskussion.....	19
Källförteckning/Referenser	21

Tabeller

Tabell 1: Mätta ledvinklar i sprintlöpningsfaser	4
--	---

Figurer

Figur 1: Förhållandet mellan AI, ML och DL	5
Figur 2: Framkopplat ANN [33]	7
Figur 3: Exempel på en faltning med ett 3x3 filter [34]	8
Figur 4: Exempel på strukturen av ett faltningsnätverk [35]	9
Figur 5: (a) Skelettbaserad modell (b) Konturbaserad modell (c) Volymbaserad modell [23]	11
Figur 6: OpenPose landmärken (version med 18 punkter) [36]	14
Figur 7: Olika delskeden i OpenPose [25]	15
Figur 8: OpenPose arkitektur [25]	16
Figur 9: Exempelbilder på användningen av OpenPose i [31]	18
Figur 10: Exempelbilder på användningen av OpenPose i [32]	19

1. Introduktion

Loppen i de första antika olympiska spelen år 776 f.Kr. kan anses som uppkomsten för det vi kallar sprintlöpning idag [1]. Sedan dess har sprintlöpning standardiserats och moderniserats till de lopp som dagligen utövas runtom i världen. Sprintloppen som fortfarande finns med i de moderna olympiska spelen är 100 meter, 200 meter och 400 meter [2].

Sprintlöpning är en form av löpning där en idrottare strävar att springa en kort sträcka så snabbt som möjligt. Rörelseanalys kan ge svar på eller antydning till hur prestationen i ett sprintlopp kan förbättras. Rörelseanalys har undersökts sedan 1960-talet [3]. Utvecklingen av datorer och möjligheten att använda datorsystem i analysen är en innovation inom datorseende. Datorseende innebär användning av artificiell intelligens för extrahering, analys och bearbetning av bild- och videoinformation, eller andra visuella indata. Det man delvis vill åstadkomma med datorseende är automatisering av typiska uppgifter som människor klarar av med sitt seende, som till exempel identifiering av objekt i en bild [4].

Kroppsställningsestimering (*eng.* Pose Estimation) är en del av rörelseanalys. Syftet med kroppsställningsestimering är att detektera en kropp eller enskilda kroppsdelar i bilder och videor [5]. Syftet med avhandlingen är att undersöka användningen av kroppsställningsestimering för analys av sprintlöpning. Undersökningen avgränsas till en kroppsställningsestimeringsmetod som kallas OpenPose eftersom den använts i tidigare undersökningar för analys av löpning.

Avhandlingen är uppdelad i tre huvudsakliga kapitel. Kapitel 2 innehåller bakgrundsinformation om de olika delarna som behandlas i senare kapitel. I kapitlet definieras sprintlöpning och dess biomekanik förklaras. I kapitel 2 förklaras artificiell intelligens, maskininlärning, djupinlärning och faltningsnätverk eftersom de är viktiga komponenter i avhandlingen. I kapitel 3 förklaras hur mänsklig kroppsställningsestimering fungerar och vilka kroppsmodeller som används i nämnd teknik. Olika metoder inom tvådimensionell och tredimensionell kroppsställningsestimering tas också upp i kapitel 3. I kapitel 4 presenteras OpenPose. Kapitlet innehåller information om hur OpenPose fungerar, samt nätverksarkitekturen i OpenPose. I kapitel 4 presenteras också tre studier där OpenPose används för att analysera olika former av löpning. I diskussionskapitlet presenteras argument för och mot användningen av OpenPose för analys av sprintlöpning, baserat på studierna. I kapitlet dras även slutsatser om OpenPose användbarhet för analys av sprintlöpning baserat på argumenten som tas upp i kapitlet.

2. Bakgrund

2.1. Sprintlöpning

I denna avhandling definieras sprintlöpning som en prestation där en människa strävar till att uppnå en maximal hastighet på en kort sträcka. Sprintlöpning har studerats sedan början av 1920-talet [6]. Ett exempel på tidig forskning är en beskrivning av hastighet jämfört med tiden under ett sprintlopp, vilket har gett grunden till senare forskning inom området [7]. Baserat på denna forskning har man delat upp sprintlöpning i tre faser: accelerationsfas, maximal hastighetsfas och retardationsfas. I Mero et al. [6] inkluderas blockstarten som en fas i sprintlöpning och fasen inkluderas även i denna avhandling. Alla fyra faser förklaras i [6] för att skapa en förståelse för vad som sker under ett sprintlopp. Denna information används även senare i avhandlingen för att diskutera användningen av OpenPose för analys av sprintlöpning.

2.1.1. Biomekanik i sprintlöpning

Biomekanik i sportsammanhang syftar till kroppens rörelse under en prestation [8]. Biomekanik i sprintlöpning har undersökts i flera studier. Syftet med forskningen är att analysera löpteknik, för att bättre förstå vad som krävs för att uppnå och upprätthålla maximal hastighet i ett sprintlopp. Viktiga komponenter i sprintlöpning är teknik, muskelaktivitet och kraftproduktion [6]. För att åstadkomma en bra löpteknik måste kroppens muskler och leder jobba på ett optimalt sätt. I följande artiklar [9, 10, 11] studeras ledvinklarna i sprintlöpningens faser.

Den första fasen är blockstarten. Blockstarten är en viktig del av ett sprintlopp. För att få den bästa möjliga starten i ett sprintlopp måste löparen ha en optimal position i blocken. Knälederna ska justeras till en vinkel där den största kraften i frånskjutningen från blocken kan åstadkommas [9]. Ledvinklarna från Harland et al. [9] finns sammanfattade i tabell 1 under kolumnen "Blockstart".

Den andra fasen är accelerationsfasen. Accelerationsfasen börjar vid första steget efter blockstarten och pågår ända tills löparen nått sin maximala hastighet. Accelerationen sker då löparen ökar steglängden och stegfrekvensen. För en elitsprinter i ett 100 meters lopp sker denna fas vanligtvis kring de första 30–50 metrarna av loppet [6]. De viktigaste lederna i denna fas är höft-, knä-, och vristlederna eftersom viktiga löppositioner under ett sprintlopp främst nås med hjälp av dessa leder [10]. Löppositionerna räknas upp i första kolumnen i tabell 1. Beroende på vilket skede av accelerationsfasen idrottaren befinner sig i varierar vinklarna. För att studera ledvinklar i accelerationsfasen utfördes en studie där man mätte ledvinklar hos tio idrottare under accelerationen [10]. Ledvinklarna från Schache et al. [10] finns sammanfattade i tabell 1 under kolumnen "Accelerationsfas".

Den tredje fasen är den maximala hastighetsfasen. Fasen börjar då löparen når den mest gynnsamma kombinationen av steglängd och stegfrekvens. Det har undersökts att efter en hastighet på 7 m/s, sker en större ändring i stegfrekvensen jämfört med steglängden [6]. Även ledvinklarna i den maximala hastighetsfasen har analyserats. En studie med 79 idrottare gjordes för att analysera ledvinklar i maximala hastighetsfasen [11]. Ledvinklarna från Miyashiro et al. [11] finns sammanfattade i tabell 1 under kolumnen "Maximal hastighetsfas".

Den fjärde fasen kallas retardationsfasen. Det är fasen då idrottaren bromsar farten efter den maximala hastighetsfasen [6]. I denna avhandling ligger fokus på de tidigare nämnda faserna eftersom fasen inte spelar en avsevärt viktig roll i den analys som utförs.

I tabell 1 presenteras ledvinklarna från de tidigare nämnda studierna. I accelerationsfasen är vinklarna mätta horisontalt och i maximala hastighetsfasen vertikalt, vilket gör det svårt att jämföra resultaten i de olika faserna. Löppositionerna i första kolumnen är indelade i positioner vid markkontakt och positioner vid frånskjut. Markkontakt syftar till ögonblicken då foten träffar marken under ett lopp. Frånskjut syftar till ögonblicken då foten lossnar från marken under ett lopp.

Det är möjligt att analysera olika faser av ett sprintlopp från videor. En viktig del av analysen är att iaktta ledernas position och vinklar eftersom optimala ledvinklar förbättrar löptekniken [9, 10, 11]. Användning av artificiell intelligens, speciellt kroppsställningsestimering, kan potentiellt hjälpa till med mätning av ledvinklar och detta tas upp senare i avhandlingen.

Tabell 1: Mätta ledvinklar i sprintlöpningens faser

	Blockstart [9]	Accelerationsfas * [10]	Maximal hastighetsfas [11]
Lutning av överkroppen	$(-21,5^\circ) \pm 7,5^\circ$	$13,9^\circ \pm 4,5 / 57,6^\circ \pm 7,9^\circ$	-
Knäleden vid markkontakt	$100,0^\circ \pm 11,0^\circ$ (främre knä) ** $127,0^\circ \pm 9,0^\circ$ (bakre knä) **	$26,3^\circ \pm 4,7^\circ / 62,8^\circ \pm 8,5^\circ$	$152,3^\circ \pm 14,2^\circ$
Knäleden vid frånskjut	-	$14,6^\circ \pm 9,7^\circ / 16,9^\circ \pm 5,4^\circ$	$155,4^\circ \pm 12,8^\circ$
Höftleden vid markkontakt	-	$44,9^\circ \pm 3,9^\circ / 64,3^\circ \pm 6,1^\circ$	$131,9^\circ \pm 8,1^\circ$
Höftleden vid frånskjut	-	$(-4,4^\circ) \pm 5,6^\circ / 4,3^\circ \pm 6,9^\circ$	$196,4^\circ \pm 13,2^\circ$
Vristleden vid markkontakt	-	$(-6,5^\circ) \pm 3,6^\circ / 11,2^\circ \pm 5,0^\circ$	$123,2^\circ \pm 10,4^\circ$
Vristleden vid frånskjut	-	$(-32,9^\circ) \pm 3,4^\circ / (-30,9) \pm 4,4^\circ$	$147,3^\circ \pm 9,4^\circ$

* i denna fas inkluderas vinklarna från början och slutet av fasen

** knävinklar i blockstarten

2.2. Artificiell intelligens


Begreppet artificiell intelligens (AI) introducerades första gången år 1956, då forskaren John McCarthy tillsammans med andra datavetare samlades i Dartmouth College, New Hampshire för att studera området vi idag kallar artificiell intelligens. McCarthy och hans kolleger föreslog att det är möjligt att beskriva inlärning och andra delar av intelligens tillräckligt noggrant för att möjliggöra simulering av detta med hjälp av en maskin [12].

I Alan Turings artikel [13] diskuterade han idén om att maskiner kunde uppnå förmågan att tänka och lära sig själv på samma sätt som en människa. Han skapade ett test för att bevisa detta, även känt som Turingtestet. Testet går ut på att en människa försöker avgöra från en konversation ifall motparten är en maskin eller människa. Ifall personen inte kan avgöra om motparten är maskin eller människa bevisar det att en maskin kan uppnå mänsklig intelligens [13].

En vanlig definition av artificiell intelligens är datorers förmåga att efterlikna mänskligt tänkande och beteende. Enligt McCarthy kan intelligens definieras som den beräkneliga delen av förmågan att uppnå mål i världen. McCarthy argumenterar för att AI delvis simulerar mänsklig intelligens, men AI behöver inte nödvändigtvis använda de metoder av intelligens vi kan observera hos människor [14].

AI har hittills implementerats i flera områden, bland annat inom spel, röstigenkänning och datorseende [14]. AI:s globala marknadsandel uppskattas växa med 37,3 % mellan åren 2023 och 2030. Trenden tyder på att investeringar i AI fortsättningsvis kommer göras i framtiden och förmodligen kommer AI att implementeras till nya användningsområden [15].

Maskininläring och djupinläring är delområden inom AI och förhållandet mellan dessa begrepp illustreras i figur 1. I delkapitel 2.3 och 2.4 förklaras begreppen maskininläring och djupinläring för att närmare klargöra deras betydelse.



Figur 1: Förhållandet mellan AI, ML och DL

2.3. Maskininläring

Maskininläring (ML) är en metod inom AI som avser en maskins förmåga att efterlikna mänsklig inläring. ML-baserade system delas ofta upp i fyra kategorier baserat på den underliggande inlärningsmekanismen som används: övervakad inläring, oövervakad inläring, halvövervakad inläring, och förstärkningsinläring [16].

Övervakad inläring (*eng.* Supervised Learning) betyder att systemet ges indata där det är specificerat vad resultatet eller utdata ska vara. Systemet lär sig genom att identifiera mönster

mellan indata och det förväntade resultatet. Systemet tränas med markerade indata där markeringen är det förväntade resultatet. Målet med övervakad inlärning är att lära system kombinera indata och utdata på ett konsekvent sätt, samt lära dem förutsäga ett resultat då nya indata ges. Klassificering av data är ett vanligt problem som kan lösas med övervakad inlärning [17].

I oövervakad inlärning (*eng.* Unsupervised Learning) skiljer sig typen av indata från övervakad inlärning. I oövervakad inlärning är indata inte markerade eller klassificerade. Målet med oövervakad inlärning är att systemet på basis av indata letar efter gömda och intressanta mönster i data. Till skillnad från övervakad inlärning kan man inte använda oövervakad inlärning för klassificering av data eftersom det inte är specificerat vilka utdata ska vara. Ett användningsområde för oövervakad inlärning är klusteranalys. Klusteranalys innebär gruppering av data i delmängder, d.v.s. kluster. Klusteranalys kan användas till exempel för att gruppera liknande data [17].

Halvövervakad inlärning (*eng.* Semi-supervised Learning) baserar sig på övervakad och oövervakad inlärning. I halvövervakad inlärning får systemet tillgång till data där en del av data är markerade med förväntat resultat, men stora delar av data är omarkerade. Halvövervakad inlärning kan användas både för klassificering och klusteranalys [17].

Förstärkningsinlärning (*eng.* Reinforcement Learning) är en inlärningsmetod där inlärningen sker med hjälp av belöning och straff. Systemet gör olika val i en interaktiv miljö och baserat på åtgärden som utförs belönas eller straffas systemet. Det som krävs för belöning är bestämt på förhand, men systemet är inte medvetet om vilka val som belönas. Förstärkningsinlärning tillämpas ofta i spel, robotik och industriell automation [18].

2.4. Djupinlärning


Djupinlärning (DL) är en metod inom maskininlärning som använder artificiella neurala nätverk för att tolka data [19]. I följande delkapitel förklaras artificiella neurala nätverk för att skapa en förståelse för hur de fungerar.

2.4.1. Artificiella neurala nätverk

Artificiella neurala nätverk (ANN) är nätverk av beräkningar som försöker imitera funktioner i människohjärnan för beslutsfattande. ANN används för maskininlärningsuppgifter där mönster extraheras från data. Nätverken är inspirerade av hjärnans neuroner och kopplingen mellan dem. ANN består av noder med kopplingar emellan dem, där en enskild nod kan motta data från flera

noder och skicka vidare data till flera noder. Det finns olika typer av neurala nätverk: framkopplade nätverk (*eng.* Feedforward Neural Network, FNN), återkopplade nätverk (*eng.* Recurrent Neural Network, RNN) och faltningsnätverk (Convolutional Neural Network, CNN). Det som skiljer nätverken är strukturen och/eller dataflödet [20].

I figur 2 presenteras ett framkopplat artificiellt neuralt nätverk med totalt fyra lager. Ett nätverk är framkopplat om en nod endast kan motta data från indatakopplingar och skicka data via utdatakopplingar [20]. I figur 2 illustreras detta med hjälp av pilar. I figuren finns tre olika typer av lager: inputlager (*eng.* Input Layer), dolda lager (*eng.* Hidden Layer) och outputlager (*eng.* Output Layer).



Figur 2: Framkopplat ANN [35]

I ett ANN behandlas data baserat på värden i noder, kopplingar mellan noder och aktiveringsfunktioner. Aktiveringsfunktioner (*eng.* Activation Functions) är en del av beräkningen i en nod. En aktiveringsfunktion avgör om ett värde är tillräckligt viktigt att aktiveras, d.v.s. om det ska skickas vidare till nästa nod. Ett exempel på en aktiveringsfunktion är stegfunktionen. Noden med stegfunktionen aktiveras om det inmatade värdet är större än noll (0). Om noden aktiveras blir värdet som skickas vidare till nästa nod ett (1). Aktiveringsfunktioner kan också vara icke-linjära. Ett exempel på en icke-linjär aktiveringsfunktion är ReLU-funktionen (Rectified Linear Unit). Noden med ReLU-funktionen aktiveras om det inmatade värdet är större än noll (0). Om noden aktiveras blir värdet som skickas vidare till nästa nod fortsättningsvis samma värde som det inmatade värdet. Hela proceduren repeteras i de följande lagren tills data når utdatalagret. I utdatalagret presenteras

den data som multiplicerats och omformats i de tidigare lagren, d.v.s. resultatet efter att data flödat igenom nätverket [20].

2.4.2. Faltningsnätverk

Faltningsnätverk är ANN som används främst i bildbehandling och igenkänning av mönster [21]. Faltningsnätverk använder en matematisk operation som kallas faltning för att skapa en summafunktion av två andra funktioner, vilket möjliggör extrahering av egenskaper i en bild. I ett faltningsnätverk sker detta med hjälp av ett filter som åker stegvis över en bild, där steglängden (*eng.* Stride) är specificerad [22]. Filtret är ett block av värden med en dimensionalitet. Ett exempel på ett filter med en 3x3 dimensionalitet illustreras i figur 3 (övre delen till höger). I figur 3 presenteras ett exempel på faltning med ett 3x3 filter. I figuren finns en 5x5 matris med ettor och nollor som föreställer pixelvärden i en bild. Värdena i 5x5 matrisen representerar egenskaper. Noll (0) betyder att egenskapen inte existerar i pixeln och ett (1) betyder att egenskapen existerar i pixeln. I nedre delen av figuren demonstreras en faltning av filtret och pixlarna i delen där filtret placerats. I nedre delen till höger finns en egenskapskarta (*eng.* Feature Map) som innehåller resultatet av faltningen. Värdena i egenskapskartan fylls i vartefter filtret åker över bilden. Ett högre värde betyder att det är mer sannolikt att en egenskap existerar i den delen.

0	1	1	0	1
0	1	1	0	1
0	1	1	0	1
0	1	1	0	1
0	1	1	0	1


1	0	1
1	1	1
0	0	1

0x1	1x0	1x1	0	0
0x1	1x1	0x1	1	0
1x0	1x0	0x1	1	1
0	0	1	1	0
0	1	1	0	0

2		

Figur 3: Exempel på en faltning med ett 3x3 filter [36]

I ett typiskt faltningsnätverk används flera faltningslager för att extrahera egenskaper på olika abstraktionsnivåer. Till exempel kan de första lagren extrahera egenskaper som hörn och kanter, medan senare lager kan extrahera delar av objekt eller hela objekt. I figur 4 illustreras strukturen av ett faltningsnätverk. Faltningsnätverk består huvudsakligen av tre typer av lager: faltningslager, poolinglager och tätt sammankopplade lager [22].



Figur 4: Exempel på strukturen av ett faltningsnätverk [37]

I faltningslagret sker faltningen av filtret och bilden som matats in i nätverket. Faltningslagret använder också icke-linjära aktiveringsfunktioner för att skapa en noggrannare approximation av egenskaperna i egenskapskartorna [23]. Poolinglagret finns till för att minska på komplexiteten av beräkningarna och för att undvika överanpassning (*eng.* Overfitting) [24]. Överanpassning betyder att en metod fungerar bra med de data som metoden tränats med, men kan inte anpassa sig för nya data. I poolinglagret görs dessa anpassningar med att minska på dimensionaliteten och mängden parametrar i faltningslagrets utdata. *Max pooling* är en funktion som ett poolinglager kan använda för att minska på dimensionaliteten [22]. I max pooling körs ett filter, med en mindre dimensionalitet, stegvis över egenskapskartorna som skapades i faltningslagret. Filtrets uppgift är att hitta det maximala värdet i det område som filtret täcker i varje steg och behålla endast dessa värden. Detta möjliggör en minskad dimensionalitet av data. Till sist klassificeras och förutsägs det slutliga resultatet i de tätt sammankopplade lagren [21].

3. Mänsklig kroppsställningsestimering


Mänsklig kroppsställningsestimering (*eng.* Human Pose Estimation, HPE) är kroppsställningsestimering av människokroppar i bilder eller videor. Genom att analysera bildinformation kan HPE-metoder identifiera leder och andra egenskaper på människokroppen och sedan presentera dem visuellt på bild. En HPE-metod börjar med att identifiera viktiga punkter på människokroppen (till exempel leder eller kroppsdelar) och kopplar sedan ihop dessa punkter för att forma en modell av en människokropp [25, 26].

Identifiering av leder och kroppsdelar från visuella indata är grunden till HPE. Modeller av människokroppen är viktiga komponenter i HPE. Ett sätt att uppskatta positioner är med hjälp av modellbaserad teknik. HPE baserar sig på någon av följande tre modeller; en skelettbaserad, en konturbaserad, och en volymbaserad modell [25]. I figur 5 illustreras nämnda modeller.

Den skelettbaserade modellen (*eng.* Skeleton-based Model) visar en position som punkter och linjer mellan punkterna. Modellen representerar sambandet mellan kroppsdelar visuellt i skelettform. Mängden punkter kan variera, men vanligtvis används 10 till 30 punkter. Linjer dras mellan de identifierade punkterna på människokroppen och det bildar ett skelettliknande mönster. Den skelettbaserade modellen har vissa begränsningar, till exempel kan modellen inte uppskatta form och textur. Skelettbaserade modeller kan användas både för tvådimensionell och tredimensionell HPE [25]. OpenPose baserar sin funktionalitet på den skelettbaserade modellen [27].

Den konturbaserade modellen (*eng.* Contour-based Model) använder människokroppens konturer för att visuellt presentera en position. Till skillnad från den skelettbaserade modellen används denna modell för att illustrera människokroppens utseende och form. Modellen används ofta i äldre HPE-metoder [25].

Den volymbaserade modellen (*eng.* Volume-based Model) illustrerar människokroppen i 3D med hjälp av geometriska kroppar, till exempel cylindrar och koner. Moderna HPE-metoder kan även skapa en 3D-människokropp (se figur 5c). På samma sätt som den konturbaserade modellen används denna modell för att konstruera människokroppens form och utseende. Den volymbaserade modellen används främst för djupinlärningsbaserad 3D HPE [25].



Figur 5: (a) Skelettbaserad modell (b) Konturbaserad modell (c) Volymbaserad modell [25]

3.1. Tvådimensionell kroppsställningsestimering

Tvådimensionell HPE (2D HPE) identifierar positionen av leder på människokroppen från monokulära bilder eller videor. Monokulära bilder och videor är tagna från endast en vinkel. 2D HPE kan delas upp i två kategorier: 2D HPE för enskilda människor och 2D HPE för flera människor [26].

2D HPE av enskilda människor identifierar positionen av en enskild person. Bilder där det förekommer flera personer kräver förbehandling av den ursprungliga bilden, där bilden beskärs så att endast en person syns. Traditionella HPE-metoder har ersatts av DL-baserade metoder som använder neurala nätverk. Användning av neurala nätverk i 2D HPE av enskilda människor fungerar med hjälp av regression eller skapandet av färgdiagram (*eng.* Heatmaps) [26].

I maskininlärning är regression en typ av övervakad inlärning där målet är att identifiera förhållanden mellan indata och utdata. En HPE-metod som använder sig av regression försöker kontinuerligt uppskatta x- och y-koordinater av kroppsdelar på en bild [28]. En HPE-metod som skapar färgdiagram gör detta med hjälp av normalfördelning. Normalfördelning innebär fördelning av värden eller data där fördelningen anger medelvärdet och spridningen av data [28]. I HPE är färgdiagrammen en representation av sannolikheten att en led eller kroppsdel finns i en viss punkt på en bild.

2D HPE av flera människor detekterar och lokaliserar flera personer i en bild eller video. Till skillnad från 2D HPE av enskilda människor är det inte definierat hur många personer som finns på bilden. För att ta reda på hur många personer som finns på bilden existerar två kategorier av HPE metoder: top-down-metoder och bottom-up-metoder [26].

Top-down-metoder letar först fram personerna och sedan identifieras positionen av personernas leder, medan bottom-up-metoder först letar fram alla leder på bilden varefter lederna kopplas ihop med personerna.

2D HPE har uppnått en detektionsgrad på över 90 % för alla leder på människokroppen. Detta har möjliggjorts genom implementering av faltningsnätverk, samt tillgång till stora mängder data [29].

3.2. Tredimensionell kroppsställningsestimering

Tredimensionell HPE (3D HPE) uppskattar en position i 3D. 3D HPE har inte utvecklats lika snabbt jämfört med 2D HPE. Det beror delvis på att nya metoder som till exempel faltningsnätverk har börjat användas tidigare i 2D HPE [29]. Moderna 3D HPE-tekniker har en 20 millimeter större felmarginal för uppskattning av kroppspunkter jämfört med 2D HPE [29].

3D HPE-metoder presterar inte lika bra som traditionella metoder av rörelseanalys eftersom noggrannheten fortfarande är bättre i de traditionella metoderna [29]. Ett exempel på en traditionell metod är användningen av fysiska markeringar på kroppen, d.v.s. markeringar fästa på ett objekt eller en människa. Utmaningen med de markörbaserade metoderna är att de krävs komplexa sensorer för att identifiera markörerna i mätningar. Mätningarna måste också ske i en kontrollerad miljö, oftast ett laboratorium. Kraven för komplexa sensorer och en kontrollerad miljö kan undvikas med hjälp av 3D HPE men noggrannheten är inte ännu tillräckligt bra för att tävla mot de traditionella metoderna [29]. De moderna 3D HPE-metoderna baserar sig på två alternativa tillvägagångssätt: monokulära bilder eller samlingar av bilder från olika vinklar [29].

I metoderna där monokulära bilder används, baseras den tredimensionella uppskattningen på tvådimensionella egenskapskartor. Ett exempel på en metod som använder monokulära bilder är VNect [29]. VNect är ett ramverk för 3D HPE i realtid. VNect skapar först tvådimensionella egenskapskartor och därefter lägeskartor (*eng.* Location Maps). Lägeskartorna uppskattar läget av x-, y- och z-koordinater för varje led i relation till höften eller nacken. På detta vis skapas en tredimensionell uppskattning av en position. Problemet med


metoden är att z-koordinaterna, d.v.s. koordinaterna i tredje dimensionen, inte är tillräckligt noggranna [29].

I metoderna där samlingar av bilder från olika vinklar används är det möjligt att använda triangulering. Triangulering är ett sätt att uppskatta positioner tredimensionellt. Triangulering används i geometri för att bestämma avståndet till en punkt från två andra punkter med känd position. I 3D HPE är det möjligt att använda triangulering för att uppskatta en position om det finns tillgång till flera kameravinklar. Noggrannheten i dessa metoder är bättre jämfört med metoderna som använder monokulära bilder [29].

4. OpenPose

OpenPose är en HPE-metod som tillåter realtidsigenkänning av kroppar, fötter, händer och ansikten från enskilda bilder och videor [27]. OpenPose möjliggör detektering av totalt 135 punkter på människokroppen. Punkterna beskriver vanligen landmärken på kroppen, till exempel leder eller kroppsdelar. Figur 6 ger ett exempel på de landmärken som metoden detekterar i en version där 18 punkter används. Det går också att aktivera och inaktivera olika landmärken enligt behov. Metoden möjliggör både 2D och 3D HPE, men kan detektera flera personer i samma bild endast i 2D. I 3D detektering krävs även flera synkroniserade kameravinklar [29].

OpenPose har ett systembibliotek för HPE som innehåller tre olika block: kropps- och fotdetektion, handdetektion och ansiktsdetektion. Dessa block är tränade med bilder där detektionspunkterna är färdigt annoterade. Alternativt kan OpenPose använda färdigt annoterade dataset som MPII (Max Planck Institut Informatik) och COCO (Common Objects in Context). MPII och COCO är dataset med tusentals bilder som har manuellt annoterade kroppsdelar [30, 31]. Dessa kan användas för träning och evaluering av HPE-metoder.




Figur 6: OpenPose landmärken (version med 18 punkter) [38]

Källkoden för OpenPose¹ är öppen, d.v.s. den finns tillgänglig för nedladdning via nätet för vem som helst [27]. OpenPose kan användas i olika operativsystem, exempelvis Windows, Mac OSX och Ubuntu. OpenPose låter användaren välja en metod för inmatning av data, där möjligheterna är bilder, videor, webbkamera och IP-kamera (övervakningskamera). Det går också att mata in bilder tagna med djupkameror eller kameror med flera linser och även strömning i realtid är möjligt [27]. Resultaten kan visuellt presenteras på en skärm i realtid eller sparas till en dator. OpenPose utdata kan omformas till CSV-format och presenteras i en CSV-fil [32]. Filen består av sex kolumner. Den första tre kolumnerna innehåller indexeringar och information om vilka kroppsdelar som detekteras. De följande två kolumnerna innehåller data om vilka x- och y-koordinater en kroppsdel befinner sig vid i en bild. Koordinaterna kan kombineras för att kolla i vilka av bildens pixlar kroppsdelarna befinner sig. Den sista kolumnen innehåller information om metodens uppskattade sannolikhet att leder eller kroppsdelar avbildas i vissa pixlar [32].

I figur 7 presenteras olika skeden en bild går igenom för att möjliggöra detektering av kroppsdelar med OpenPose. Figur 7a är bilden som matas in i systemet. Figur 7b illustrerar skapandet av 2D färgdiagram över lederna och/eller kroppsdelarna. Färgdiagrammen representerar sannolikheten att kroppsdelar avbildas i vissa pixlar. Figur 7c illustrerar skapandet

¹ <https://github.com/CMU-Perceptual-Computing-Lab/openpose.git>

av 2D vektorfält, s.k. samhörighetsfält (*eng.* Part Affinity Fields). Samhörighetsfältens funktion är att associera punkterna på bilden för att skapa en logisk presentation av kroppsdelar. I figur 7d går färgdiagrammen och samhörighetsfälten igenom en parsning. Parsning innebär att delarna analyseras systematiskt, en i taget, och kopplas ihop för att producera resultatet som presenteras i figur 7e.




Figur 7: Olika delskeden i OpenPose [27]

4.1. Arkitektur

Nätverksarkitekturen i OpenPose visas i figur 8. Nätverket består av två huvuddelar, en del för skapandet av samhörighetsfält L och en annan del för skapandet av färgdiagram S . I figur 8 är den förstnämnda delen betecknad med ϕ och den andra delen med p . Båda delarna innehåller faltningslager där lagren är indelade i block. I nedre delen av figuren illustreras hur varje ljusrött block C består av tre 3×3 faltningsfilter. Antalet färgdiagram S och samhörighetsfält L bestäms enligt antalet kroppsdelar som OpenPose ska detektera [27].

När en bild inmatas i nätverket går den först igenom ett faltningsnätverk F . Faltningsnätverket F skapar egenskapskartor som sedan matas in i första skedet av nätverket. Egenskapskartorna flödar sedan igenom ϕ -delen där samhörighetsfälten L skapas. Delen består av 5 faltningsblock C och två 1×1 filter. I slutet av delen används en förlustfunktion (*eng.* Loss Function) som jämför nätverkets utdata med ett förväntat resultat. Parametrarna i nätverket kan justeras för att minimera förlusten, d.v.s. maximera noggrannheten i resultaten.

Samhörighetsfälten flödar sedan igenom p -delen där färgdiagrammen S skapas. Delen består av 5 faltningsblock C , två 1×1 filter och en förlustfunktion. I nätverket är totala antalet beräkningar 51, för varje skede t . Ett ökat antal skeden t möjliggör noggrannare resultat men kräver mera beräkningar av nätverket. Olika versioner av OpenPose använder olika många skeden t för att minska på körtiden eller öka på noggrannheten [27].



Figur 8: OpenPose arkitektur [27]

4.2. OpenPose för analys av sprintlöpning

För att diskutera hur bra OpenPose fungerar för analys av sprintlöpning undersöks användningen av OpenPose i tre olika studier. Den första studien är ett exempel på hur OpenPose kan användas för att analysera prestandan i ett sprintlopp. De två andra studierna är undersökningar om noggrannheten av OpenPose då den används för att detektera leder och kroppsdelar i någon form av löpning. Dessa tre studier valdes för att undersöka hur OpenPose kan användas i praktiken för rörelseanalys och för att samla information om hur bra eller dåligt OpenPose fungerar.

4.2.1. Sprintlöpning mellan koner

I artikel [32] används OpenPose för att studera sprintlöpning mellan koner. Målet med undersökningen var att analysera hur lutning av överkroppen påverkar prestandan i ett sprintlopp. I studien användes OpenPose med 18 punkter för att analysera loppet.

I undersökningen bad man unga fotbollsspelare löpa en 16,5 meter lång sträcka fram och tillbaka två gånger, d.v.s. totalt 66 meter. Loppet i undersökningen filmades med en vanlig

smarttelefon i högdefinition (60fps, 1920x1080 upplösning). Telefonen var fäst på ett stativ för att undvika onödigt svajande i videoklippen. Filmandet utfördes utomhus på en gräsplan. Totalt 50 videor användes i analysen. Koordinaterna i videorna extraherades från varje bild i videorna med hjälp av en CSV-fil som innehöll information om var lederna finns i bilden. Punkterna vid lederna användes sedan för att mäta lutningen av överkroppen i grader. I studien kom man fram till att en mer upprätt position av överkroppen resulterar till en högre hastighet i den maximala hastighetsfasen.

I artikelns diskussion kommenteras även hur OpenPose påverkade resultaten. Det nämns att OpenPose hade flera borttappade värden i CSV-filen. Det nämns också att en för liten mängd data kan ha påverkat resultatet.


4.2.2. Häcklöpning

I artikel [33] analyseras hur noggrant OpenPose kan identifiera kroppsdelar i häcklöpning. Målet med studien var att skapa ett system för 2D HPE baserat på OpenPose för häcklöpning. OpenPose testades med tre olika nätverksarkitekturer: VGG19, Mobilenet-v2-large och Mobilenet-thin. I studien jämfördes nätverken baserat på noggrannhet och körtid. I studien användes OpenPose med 17 punkter där bilderna annoterades baserat på COCO.

I undersökningen löpte en atlet över häckar där tre kameror var placerade 11 meter från banan. Videorna filmades i högdefinition (120fps, 1920x1080 eller 1920x720 upplösning). Den första kameran filmade tredje och fjärde häcken, den andra kameran filmade endast fjärde häcken och den tredje kameran filmade fjärde och femte häcken. Filmandet utfördes utomhus på en löpbana. Totalt 444 bilder användes från 9 videor och bildernas upplösning ändrades till 432x368 för att försnabba körtiden av nätverket.

Själva testningen av OpenPose gjordes baserat på noggrannhet och körtid. Noggrannheten mättes med hjälp av Root Mean Square Error (RMSE). RMSE används för att mäta skillnaden mellan ett systems uppskattade värden och sanna värden. I studien mättes RMSE i antalet pixlar mellan OpenPose och en människas annoterade punkter i en bild. I studien kom man fram till att OpenPose med VGG19 är noggrannare än de två andra nätverken, men körtiden är längre i VGG19. VGG19 lyckades identifiera små leder noggrannare än de andra nätverken. Nätverket visade även bäst resultat i problemsituationer där vissa leder syntes dåligt på grund av störningar i indata. I figur 9 illustreras exempel på resultaten från OpenPose i studien.

I undersökningen diskuteras olika felsituationer som uppstod i mätningen. Till exempel hade OpenPose borttappade värden, falskt positiva värden och överlappande värden. En faktor som kan ha påverkat resultatet var att endast högra sidan av kroppen syntes största delen av tiden.



Figur 9: Exempelbilder på användningen av OpenPose i [33]


4.2.3. Löpning på löpband

I artikel [34] används OpenPose för att studera hur noggrant leder kan identifieras när personer löper på löpband. Målet med studien var att jämföra OpenPose och DeepLabCut (ett verktyg för kroppsställningsestimering för djur) med ett traditionellt mätningssystem där fysiska markeringar används. Detta gjordes med HPE av höftleden, knäleden och vristleden under löpning. I studien jämfördes även olika löpningshastigheter för att analysera noggrannheten av mätningarna i olika hastigheter. I studien användes OpenPose med 25 punkter.

I undersökningen deltog 40 personer där var och en löpte ett fyra minuters lopp på ett löpband. Före loppet fästes 46 markörer på kroppen för att möjliggöra mätning för metoden med markörer. Under loppet sprang personerna konstanta hastigheter på 2,78 m/s och 3,33 m/s. Videorna filmades med 13 kameror, varav 12 användes för metoden med markörer och endast en för OpenPose och DeepLabCut. Kameran som användes för OpenPose och DeepLabCut var placerad på högra sidan av löpbandet och videorna filmades med 659x494 upplösning.

För att göra resultaten jämförbara mellan metoderna gjordes en tidsmässig justering av detektionen, d.v.s. tiden för olika händelser i metoderna justerades så att de sker samtidigt. Jämförelsen av noggrannheten gjordes sedan med hjälp av RMSE. I studien mättes RMSE av ledvinklarna i grader. Resultatet visar att efter en tidsmässig justering är skillnaden mellan metoderna inte signifikant för hastigheten 2,78 m/s. Hastigheten 3,33 m/s visade större

skillnader mellan metoderna, där markörbaserade metoden presterade bättre än OpenPose och DeepLabCut. I figur 10 illustreras exempel på resultaten från OpenPose-algoritmen i studien.



Figur 10: Exempelbilder på användningen av OpenPose i [34]

5. Diskussion

I kapitel 4 presenterades tre studier där OpenPose används för detektering av leder i någon form av löpning. I detta kapitel diskuteras argument för och mot användningen av OpenPose för analys av sprintlöpning baserat på resultaten av de tidigare nämnda studierna. I slutet av kapitlet dras slutsatser om OpenPose användbarhet för analys av sprintlöpning baserat på argumenten.

I artikel [32] visades att lutning av överkroppen påverkar prestandan i den maximala hastighetsfasen. För att få reda på lutningen av överkroppen i studien behövde endast höftleden undersökas. Undersökningen gav inte svar på hur algoritmen fungerar för andra viktiga leder i sprintlöpning. I studien bevisades att det är möjligt att använda en vanlig smarttelefon för att filma videoklipp som sedan går att använda i OpenPose. I undersökningen stötte man på borttappade värden i filen, vilket antyder om att OpenPose inte klarar av att prestera konsekvent.

I artikel [33] diskuteras noggrannheten av OpenPose. I studien uppmärksammas felsituationer som uppstod i användningen av OpenPose. Falskt positiva värden och överlappande värden existerade i undersökningen. I undersökningen nämns att noggrannheten

försämrades på grund av att videorna filmades från sidan och endast ena sidan av kroppen syntes på videorna.

I artikel [34] visades att OpenPose fungerar mindre noggrant i högre hastighet. Redan en liten ökning av hastighet från 2,78 m/s till 3,33 m/s försämrar noggrannheten av detektionen i algoritmen. Studien visade också att OpenPose fungerar sämre än traditionella markörbaserade metoder.

Studierna visar att det finns vissa fördelar med OpenPose. Till exempel möjliggjorde OpenPose ett betydande resultat i [32] och detta kan användas som ett argument för användningen av OpenPose för analys av sprintlöpning. Ett annat argument för användningen av OpenPose är att vem som helst har tillgång till OpenPose källkod och kan ladda ner den via nätet. Obegränsad åtkomst möjliggör flera användare av metoden. Ett tredje argument för användningen av OpenPose är möjligheten för inmatning av bilder tagna med olika kameror. Det möjliggör till exempel användningen av en smarttelefonskamera.

Argumenten mot användningen av OpenPose för analys av sprintlöpning överväger fördelarna med metoden. En nackdel med OpenPose är att den inte ger information om ledvinklar i realtid. För att få tillgång till informationen krävs extrahering och tolkning av data från en fil, vilket betyder att det måste göras ytterligare arbete för att åstadkomma detta. Omedelbar feedback av löptekniken är nödvändigt för att möjliggöra en effektiv träning. Jämförelsen av OpenPose och den traditionella markörbaserade metoden i [34] visade att OpenPose inte ännu presterar lika bra som den markörbaserade metoden, särskilt vid högre hastigheter. Det indikerar att ytterligare utveckling krävs.

Det starkaste argumentet mot användningen av OpenPose för analys av sprintlöpning är den försämrade noggrannheten i högre löphastigheter. Sprintlöpning är en form av löpning där snabba rörelser sker konstant. OpenPose lider också av borttappade värden, falskt positiva värden och överlappande värden, vilket påverkar tillförlitligheten i analysen. I praktiken betyder dessa felmarginaler till exempel att ledvinklarna under ett lopp kan tolkas vara mer optimala eller mindre optimala än de är i verkligheten. Detta kan leda till att löptekniken försämrats då ledvinklarna justeras.

Min åsikt om OpenPose användbarhet är varierande. Jag önskar att OpenPose kunde användas mer inom sprintlöpning, men det kräver att metoden utvecklas i framtiden. Även argumenten tyder på att OpenPose behöver förbättras när det gäller körtid, noggrannhet och förmågan att hantera snabba rörelsemönster innan den kan användas effektivt för analys av sprintlöpning.

Källförteckning/Referenser

- [1] S. G. Miller, "The Events," i *Ancient Greek Athletics*, Yale University Press, 2004, pp. 31-87.
- [2] R. Venkat, "www.olympics.com," International Olympic Committee, 11 Juni 2021. [Online]. Available: <https://olympics.com/en/news/athletics-track-and-field-sprints-marathons-jumps-throws-heptathlon-decathlon>. [Använd 5 Maj 2024].
- [3] L. Chen, H. Wei och J. Ferryman, "A survey of human motion analysis using depth imagery," *Pattern Recognition Letters*, vol. 34, nr 15, pp. 1995-2006, 2013.
- [4] V. Wiley och T. Lucas, "Computer Vision and Image Processing: A Paper Review," *International Journal Of Artificial Intelligence Research*, vol. 2, nr 1, pp. 28-36, 2018.
- [5] T. B. Moeslund och E. Granum, "A Survey of Computer Vision-Based Human Motion Capture," *Computer Vision and Image Understanding*, vol. 81, nr 3, pp. 231-268, 2001.
- [6] A. A. Mero, P. Komi och R. Gregor, "Biomechanics of Sprint Running," *Sports Medicine*, vol. 13, nr 6, pp. 376-392, 1992.
- [7] A. Hill, *Muscular movement in man: the factors governing speed and recovery from fatigue*, McGraw-Hill, 1927.
- [8] W.-H. Tai, R. Zhang och L. Zhao, "Cutting-Edge Research in Sports Biomechanics: From Basic Science to Applied Technology," *Bioengineering*, vol. 10, nr 6, p. 668, 2023.
- [9] M. Harland och J. R. Steele, "Biomechanics of the Sprint Start," *Sports Medicine*, vol. 23, pp. 11-20, 1997.
- [10] A. G. Schache, A. K. Lai, N. A. Brown, K. M. Crossley och M. G. Pandy, "Lower-limb joint mechanics during maximum acceleration sprinting," *Journal of Experimental Biology*, vol. 222, nr 22, 2019.
- [11] K. Miyashiro, R. Nagahara, K. Yamamoto och T. Nishijima, "Kinematics of Maximal Speed Sprinting With Different Running Speed, Leg Length, and Step Characteristics," *Frontiers in Sports and Active Living*, vol. 1, nr 37, 2019.
- [12] J. McCarthy, M. Minsky, N. Rochester och C. Shannon, "A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence," 1955.
- [13] A. M. Turing, "Computing Machinery and Intelligence," *Mind*, vol. 49, pp. 433-460, 1950.
- [14] J. McCarthy, *What is Artificial Intelligence?*, Stanford: Stanford University, 2007.

- [15] Grand View Research, "Artificial Intelligence Market Size, Share & Trends Analysis Report By Solution (Hardware, Software, Services), By Technology (Deep Learning, Machine Learning, NLP), By Function, By End-use, By Region, And Segment Forecasts, 2023 - 2030," 2023.
- [16] T. W. Edgar och D. O. Manz, "Chapter 6 - Machine Learning," i *Research Methods for Cyber Security*, Syngress, 2017, pp. 153-173.
- [17] K. El Bouchefry och R. S. de Souza, "Chapter 12 - Learning in Big Data: Introduction to Machine Learning," i *Knowledge Discovery in Big Data from Astronomy and Earth Observation*, Elsevier, 2020, pp. 225-249.
- [18] A. G. Barto och R. Sutton, *Introduction to Reinforcement Learning*, London: MIT Press Cambridge, 1997.
- [19] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie och L. Farhan, "Review of deep learning: concepts, CNN architectures, challenges, applications, future directions," *Journal of Big Data*, vol. 8, 2021.
- [20] O. A. M. López, A. M. López och J. Crossa, "Fundamentals of Artificial Neural Networks and Deep Learning," i *Multivariate Statistical Machine Learning Methods for Genomic Prediction*, 2022, pp. 379-425.
- [21] H. Hong, D. Choi, N. Kim, H. Lee, B. Kang, H. Kang och H. Kim, "Survey of convolutional neural network accelerators on feld-programmable gate array platforms: architectures and optimization techniques," *Journal of Real-Time Image Processing*, vol. 21, 2024.
- [22] K. O'Shea och R. Nash, "An Introduction to Convolutional Neural Networks," 2015.
- [23] R. Wu, X. Guo, J. Du och J. Li, "Accelerating Neural Network Inference on FPGA-Based Platforms—A Survey," *Electronics*, 2021.
- [24] H. Gholamalinezhad och H. Khosravi, "Pooling Methods in Deep Neural Networks, a Review," 2020.
- [25] Y. Chen, Y. Tian och M. He, "Monocular human pose estimation: A survey of deep learning-based methods," *Computer Vision and Image Understanding*, vol. 192, 2020.
- [26] C. Zheng, W. Wu, C. Chen, T. Yang, S. Zhu, J. Shen, N. Kehtarnavaz och M. Shah, "Deep Learning-based Human Pose Estimation: A Survey," *ACM Computing Surveys*, pp. 1-37, 2023.

- [27] Z. Cao, G. Hidalgo, T. Simon, S.-E. Wei och Y. Sheikh, "OpenPose: Realtime Multi-Person 2D Pose Estimation Using Part Affinity Fields," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 43, nr 1, pp. 172-186, 2021.
- [28] Y. Li, S. Yang, P. Liu, S. Zhang, Y. Wang, Z. Wang, W. Yang och S.-T. Xia, "SimCC: a Simple Coordinate Classification," PCL Research Center of Networks and Communications, 2022.
- [29] Y. Desmarais, D. Mottet, P. Slangen och P. Montesinos, "A review of 3D human pose estimation algorithms for markerless motion capture," *Computer Vision and Image Understanding*, vol. 212, 2021.
- [30] D. C. Luvizon, D. Picard och H. Tabia, "2D/3D Pose Estimation and Action Recognition using Multitask Deep Learning," 2018.
- [31] cocodataset.org, "cocodataset.org," cocodataset.org, 6 Maj 2024. [Online]. Available: <https://cocodataset.org/#home>. [Använd 6 Maj 2024].
- [32] K. v. d. Meijden, *Analyzing sprint features with 2D Human Pose Estimation*, Tilburg: Tilburg University, 2019.
- [33] P. Jafarzadeh, P. Virjonen, P. Nevalainen, F. Farahnakian och J. Heikkonen, "Pose Estimation of Hurdles Athletes using OpenPose," *International Conference on Electrical, Computer, Communications and Mechatronics Engineering*, pp. 1-6, 2021.
- [34] B. V. Hooren, N. Pecasse, K. Meijer och J. M. N. Essers, "The accuracy of markerless motion capture combined with computer vision techniques for measuring running kinematics," *Scandinavian Journal of Medicine & Science in Sports*, vol. 33, nr 6, pp. 966-978, 2023.
- [35] A. C. Müller, "Neural Networks," i *Applied Machine Learning in Python*, 2020.
- [36] Y. Gavrilova, "Convolutional Neural Networks for Beginners," Serokell, 2021.
- [37] V. H. Phung och E. J. Rhee, "A High-Accuracy Model Average Ensemble of Convolutional Neural Networks for Classification of Cloud Image Patches on Small Datasets," *Applied Sciences*, vol. 9, 2019.
- [38] www.reddit.com, "www.reddit.com," 27 Februari 2023. [Online]. Available: https://www.reddit.com/r/StableDiffusion/comments/11cuztu/openpose_controlnet_preprocessor_options/. [Använd 5 Maj 2024].